예측 개선은 인계 성공을 개선하는가

문제 정의 · 학습/계획 설계 · 통제 비교 · 실패 분석 · 재현 범위

핵심 근거는 본문에 수록했다. 세부 코드·수치는 공개 저장소로 연결한다. GitHub PDF 미리보기에서는 링크가 동작하지 않으므로 내려받아 사용한다.

목차

초록 2

1. 문제와 연구 질문 2

2. 처음 목표와 최종 달성 수준 3

3. 시스템과 입출력 계약 3

4. 비교 방법과 학습 개입 4

5. 실험과 판정 규약 5

6. 결과 7

7. 관찰된 차이와 남은 원인 가설 9

7.1 확인된 사실 10

7.2 남은 경쟁 가설과 구별 방법 10

8. 개발 과정에서 실제로 좁힌 설명 11

9. 한계와 해석 11

10. 결론 12

부록 A. PDF만으로 확인하는 핵심 증거 12

부록 B. 재현 단계와 문서 운영 12

참고문헌 13

부품 밀기 정렬의 학습 동역학·행동 선택·폐루프 결과 비교

기술 보고서 · 2026-10-22 · 사후 종합본 · 리뷰 반영본

초록

부품 공급 셀에서 다음 작업에 넘길 자세를 만드는 상황을 배경으로, 학습한 미래 예측의 개선이 행동 선택과 실제 인계 성공으로 이어지는지 평가했다. 고정 형상의 직사각형 부품과 XY 푸셔를 사용한 MuJoCo 시뮬레이션에서 기하 피드백 G, 선형 동역학 R, 한 단계 학습 S1, 다단계 자유 예측 손실을 추가한 SK를 비교했다. 12개 독립 초기조건에서 총 96개 폐루프 실행을 기록하고, 별도의 고정 상태·후보 진단에서 576회 실제 미래를 실행했다. G/R/S1/SK의 성공은 각각 8/12, 0/12, 13/36, 12/36이었다. S1·SK의 36회는 12개 초기조건과 학습 seed 3개의 조합이다. 일부 seed에서 SK의 고정 행동 K5·K10 위치 예측오차는 작았으나, 후보 선택손실과 인계 성공 개선은 확인되지 않았다. 본 결과의 기여는 새 알고리즘이나 산업 효과의 입증이 아니라, 예측·선택·작업의 연결을 분리해 검증하고 부정 결과와 재현 근거를 남긴 데 있다.

1. 문제와 연구 질문

수평 작업대 위 어긋난 부품을 옆에서 밀어 지정 위치·방향으로 맞춘다. 잠재 사용자는 부품 공급·취급 셀의 정렬 방식을 검토하는 자동화 엔지니어다. 부품의 자세를 유지해 공급할 필요는 공개 사례로 확인되지만, 이번 밀기 정렬 모듈에 대한 고객 수요는 가설이다. 인계 후 집기·삽입은 실행하지 않았다.

Fortville Feeders의 공개 사례는 작은 플런저를 로봇이 집도록 방향과 위치를 유지하는 과제를 전용 툴링·트랙·셔틀로 해결했다. 이 사례는 작업의 의미와 기계식 대안을 뒷받침하며 학습 모델의 필요성을 입증하지 않는다 [1]. 별도 정렬 없이 현재 자세에서 직접 집기, 지그·피더, 기하 피드백도 타당한 대안이다.

Yu 등의 실물 평면 밀기 연구는 형상·표면·속도 등 여러 조건을 바꿔 마찰과 모델 가정을 분석했다 [2]. Bauza 등의 연구는 학습한 GP 동역학을 MPC에 연결했다 [3]. 이번 구성은 해당 논문의 직접 재현이 아니며, 학습 동역학과 계획의 결합 자체를 새 기여로 주장하지 않는다. 기존 접근을 작은 자원에서 구현하고 학습 손실의 제한된 효과를 비교하는 기술 검증이다.

예측 학습과 제어 성과의 목적 불일치는 선행 연구에서 다뤘다 [4]. 예측을 다시 입력할 때의 분포 변화와 다단계 학습도 알려진 연구 주제다 [5]. 본 실험의 기여는 그 현상의 최초 발견이 아니라 고정한 학습 절차·과제의 제한된 실증 비교다.

주된 비교는 S1과 SK의 손실 개입이다. RQ1은 같은 실제 상태·행동에서 위치 예측오차와 무효 수의 차이, RQ2는 같은 후보의 실제 비용 선택손실 차이, RQ3는 자체 정책의 인계 성공 차이다. 고정 행동 예측·E1·E2가 각각 답한다. 학습 모델을 구현하는 것은 선정 목표이며, 그 모델이 더 좋다는 결론은 실험 대상이다. 정형 학술 원고는 같은 결과의 수식·방법을 상세히 기술한다.

2. 처음 목표와 최종 달성 수준

최초 목표	최종 판정	근거와 남은 범위
가치 있는 작업과 비교 질문 정의	달성	인계 조건·대안·한계 명시. 현장 수요·ROI는 미검증
학습 동역학을 실제 행동에 연결	달성	신경망 재귀 예측으로 후보 선택 후 실제 접촉 실행
손실 개입과 예측·선택·작업 평가 분리	달성	S1/SK 통제 비교, 고정 예측·E1·E2 각각 완료
인계 가능한 실행 확보	일부 조건에서 달성	G·S1·SK 성공 사례. 모든 조건 해결 아님
다단계 학습의 작업 성능 개선	확인 못함	SK-S1 성공 차이 -2.78%p, 선택손실 개선 없음
실패 재현·가설 구별	부분 달성	실패를 재현하고 일부 설명을 좁힘. 단일 근본 원인 미확정
재현 가능한 결과 묶음	선별 검산 가능	실제 제어 재현 33건과 원본 보존. 공개본의 전체 재실행은 제한
사용자 개인의 설명·수정 역량	별도 확인 필요	산출물 확보와 개인 역량 검증은 다름

원래 실험·보고서 작업은 28/28개 완료했다. 이는 작업 관리의 완료다. 전체 성공률 목표와 최소 의미 개선 폭을 사전에 지정하지 않았으므로 성능 목표 달성으로 바꾸어 읽지 않는다. 개인 이해 상태는 NOT_ASSESSED다. 사용자가 상태 표현·손실·실패 원인을 직접 설명하고 작은 변경을 검증하는 확인은 별도다.

3. 시스템과 입출력 계약

현재 관측 → 후보 명령열 → 학습 모델의 미래 예측 → 비용과 유효성 비교 → 첫 명령 실행 → 새 관측의 순서로 작동한다. 모델이 학습하는 것은 행동 조건부 상태 변화다. 후보 생성·최소 비용 선택·속도 제어·접촉 물리·인계 판정을 모두 학습한 정책은 아니다.

경계	표현	의미
관측 s	10차원	부품 x,y,yaw,vx,vy,wz와 푸셔 x,y,vx,vy
명령 u	2차원	world XY 목표 속도, 0.1초 유지
모델 입력 phi(s,u)	11차원	상대 XY, sin(2yaw),cos(2yaw), 부품 속도 3, 푸셔 속도2, 명령2
모델 출력	10차원	다음 0.1초 전체 상태 증분의 정규화 예측

위치·각도·속도 단위는 m·rad·m/s·rad/s다. 목표 속도와 실제 푸셔 속도는 다를 수 있다. 푸셔의 미래 상태도 모델 출력에 포함하며 명령×시간으로 대체하지 않는다. 정규화는 train 통계로 고정한다. 목표 자세는 동역학 입력이 아니라 계획 비용에 사용한다.

MLP는 11→128→128→10, SiLU 활성화와 선형 출력이다. 네트워크는 float32, 물리 경계는 float64다. 예측 증분을 역정규화해 현재 상태에 더하고, 이후에는 예측한 전체 상태를 다시 입력한다. yaw 전이 잔차의 2π wrap과 직사각형 작업 방향의 π 대칭을 구분한다. 이 상태 표현이 숨은 접촉 상태의 충분통계임을 증명하지는 않았다.

온라인에서는 128개 후보를 H5, 즉 0.5초까지 예측해 원래 9항 가중 비용으로 평가한다. 첫 0.1초만 실행한 뒤 재관측한다. 영 명령·이전 최적열·기하 제안과 난수 후보를 사용하는 shooting 방식이다. 공통 규칙을 사용해도 서로 다른 폐루프 상태와 warm start 때문에 매 시점 후보 배열까지 같지는 않다.

실제 속도 추종과 접촉 적분은 기존 제어기·MuJoCo가 담당한다. 실제 위치·방향이 목표 범위 안이면 공통 감독기가 영 명령을 적용해 정지·유지를 검사한다. 인계 성공은 계획과 이 규칙의 결합 결과다. 학습 계획 중 실제 미래 물리를 조회하지 않는다. E1에서 후보의 실제 미래를 실행하는 것은 선택 이후의 오프라인 진단이며 온라인 oracle이 아니다.

9항 비용은 위치·방향·명령 크기·명령 변화·푸셔 간격의 다섯 단계 항과, 마지막 위치·방향·선속도·각속도 네 항이다. 0.3초 유지시간이나 미래 목표 진입 시 감독기 전환은 명시적으로 최적화하지 않는다. 비용 선택손실과 실제 인계 성공은 서로 다른 보고량이다.

4. 비교 방법과 학습 개입

표 읽는 법. G는 후보 탐색 없는 직접 기하 피드백이다. R은 같은 11차원 특징의 선형 동역학 모델(선정된 정규화 α=0), S1은 한 단계 오차로 학습한 다층 퍼셉트론(MLP), SK는 같은 MLP에 0.1 × 5단계 자유 예측 손실을 추가한 방법이다. R·S1·SK는 온라인에서 후보 128개·계획 5단계의 공통 계획기를 사용한다. 다음 표의 비교는 모델 계열과 학습 목적을 구분하며 G와 모델 계획기의 차이를 순수한 신경망 효과로 해석하지 않는다.

방법	미래 예측	행동 생성과 비교 의미
G	학습 예측 없음	조정된 기하 피드백. 전체 제어 구성의 기준선
R	선형 증분 모델	공통 계획기에서 단순 예측 기준선
S1	MLP 한 단계 학습	같은 실제 전이 창의 한 단계 오차 학습
SK	MLP 한 단계+자유 예측 학습	S1과 통제한 출발점에서 다단계 항의 효과

R은 Ridge 계열에서 α=0이 선택됐으므로 최종 예측기는 무정규화 선형 회귀다. R·S1·SK는 공통 계획기를 공유한다. G와 학습 계획기의 차이에는 제어 구조도 포함되므로 그 차이를 모두 신경망의 인과 효과로 해석하지 않는다.

G는 후퇴·접선 이동·접근·밀기의 상태기계다. yaw·각속도에 따라 뒤쪽 접촉 오프셋을 조정하고 현재 형상 경로 검사와 전환 완화를 사용한다. R은 같은 11차원 특징의 정규화 잔차 제곱합에 적합하며, 절편은 벌점에서 제외하고 α 후보 8개를 validation K5로 선정했다. G의 위치 이득과 N128/H5 계획은 이전 개발 3조건의 5초 대리 평가에서 정했다. 각 수식과 선정 범위는 학술 원고와 공개 설정에 제공한다.

seed 11·23·47마다 S1/SK는 공통 가중치·Adam 상태·RNG·정규화·자료·배치 순서에서 출발해 각각 1,000 update를 추가했다. S1의 한 단계 항은 K5 창의 실제 전이들을 사용한다. SK는 초기 실제 상태에서 출발한 자유 예측의 K1~K5 상태 오차를 추가한다. 유효 전이와 출력 10차원에 따른 분모를 고정하고 종료 뒤 padding은 제외한다.

$L_{S1} = L_{one}$이고 $L_{SK} = L_{one} + 0.1 \times L_{rollout}$이다. λ는 validation에서 선정했다. 두 군은 같은 update 수를 사용하지만 SK는 forward가 추가되므로 같은 FLOPs·시간 예산으로 해석하지 않는다.

같은 갱신 수가 목적별 수렴 정도를 맞추는 것은 아니다. 추가 항이 기울기 크기·clipping·Adam 경로에 주는 변화와 다단계 예측 오차를 학습하는 효과를 분리하지 않았다. 결론은 이 출발점·선정 가중치·학습률·1,000회 추가 갱신 절차에 한정한다. 선정의 수치·yaw 유효성과 최종 예측·계획의 작업공간·침투 검사는 다르다.

최종 비교는 P4-02 update1000 체크포인트와 원래 H5 비용을 사용했다. 이후 D11 자료 보완, R1 상대 위치 학습항, 인계 우선 H10 비용은 개발 진단이며 최종 모델·비용으로 승격하지 않았다. 개발 진단의 결과를 최종 정책의 원인 증명으로 섞지 않는다.

5. 실험과 판정 규약

목표 자세는 [0.08m, 0, 0]이다. 성공 ready는 위치 오차 5mm 이하, 방향 오차 3° 이하, 선속도 0.01m/s 이하, 각속도 0.05rad/s 이하를 실제 물리 관측에서 연속 0.3초 유지한 경우다. 최대 30초·작업 재시도 0회, 물리 간격은 0.5ms다. 이 문턱은 산업 공차가 아닌 실험 명세다.

평가 표 읽는 법. G는 기하 피드백 경로이며, S1은 한 단계 학습 MLP, SK는 한 단계 손실에 0.1 × 5단계 자유 예측 손실을 추가한 MLP다. R은 선형 예측 기준선이다. K는 0.1초짜리 미래 예측 단계 수로

K1·K5·K10은 각각 0.1·0.5·1.0초다. H는 행동 계획 길이이며 온라인 H5와 오프라인 K10 진단은 구분한다. Family는 독립 초기조건 묶음이고, seed 11·23·47은 신경망 학습 난수 설정이다. 같은 family의 여러 seed, 겹치는 예측 창, 같은 후보의 재실행을 독립 초기조건으로 추가하지 않는다.

평가	고정·실행 내용	독립성·해석
고정 행동 예측	G의 12개 실제 경로, K1/K5/K10 재귀 예측	독립 family 12. 겹치는 창은 독립 표본 아님
E1 후보 선택	G의 초기·2.9초 12상태×16후보×3실행=576회	독립 family 6. 7모델이 실제 라벨 공유
E2 인계 작업	병진·회전·오프셋 각4조건×8방법=96회	독립 family 12. 신경망은 3seed
E3 학습 손실	E1/E2의 S1·SK 비교	새 물리 실행 수를 더하지 않음
실제 제어 재현	사전 선정 규칙의 33사례 재실행	저장 수치 재집계와 별도 증거
작은 적용	같은 범위의 예약 13번째 family×8방법	E2와 합치지 않음. 새 태스크·OOD 아님

성공 비율 차이는 family 내부 seed를 먼저 평균하고 층 내 family bootstrap 2,000회, seed 7711의 95% percentile 구간으로 나타냈다. 여러 탐색적 비교의 다중비교 보정은 하지 않았다. 0을 포함한 구간은 동등성 증거가 아니다.

이는 고정한 학습 seed와 초기조건 설계 범위의 재표집 구간이며 학습 seed 모집단이나 산업 발생률 전체의 불확실성을 포함하지 않는다.

E1 선택손실은 선택 후보의 실제 평균 비용에서, 세 반복 모두 유효한 후보 중 최소 실제 평균 비용을 뺀 값이다. 유한 후보군에 대한 후회 비용이며 전역 최적 제어와의 차이가 아니다. 반복 비용 범위가 겹치는 순위는 INCONCLUSIVE로 남긴다. 해당 범위는 신뢰구간이 아니다.

순위 비교는 실제 반복 범위 양쪽에 $\varepsilon=10^{-6}+10^{-5}\times$후보 반복비용 절댓값 최댓값을 더한다. 세 실제 반복은 같은 후보의 상태·명령·비용이 동일했으므로 물리 잡음의 분산 추정이 아니라 결정론적 재현 검사다. E1의 회전·오프셋 층은 양의 초기 회전·접선 오프셋만 포함하고, 시작 위치오차는 56.067-93.612mm, 실제 후보 끝점 최소 오차는 49.462mm였다. 종단 5mm 정렬·정지·유지를 직접 표집하지 않았다.

첫 정식 실행은 R 제어 후 저장 과정에서 중단됐다. 첫 실행·부분 원시는 보존하고 저장기만 보완해 같은 과학 조건으로 실행02를 새로 시작했다. 초기조건은 복구 전에 결과 일부를 알게 된 조건이므로 새로 뽑은 미공개 시험이라고 하지 않는다. 부모 결과를 합치거나 유리한 결과를 골라 교체하지 않았다. 집계 순서의 미세 부동소수 차이도 원본을 보존한 별도 분석에서 순서를 고정해 해결했다.

6. 결과

표 1. 층별 인계 성공/전체 실행. G는 기하 피드백, R은 선형 예측(α=0), S1은 한 단계 학습 MLP, SK는 같은 MLP에 0.1 × 5단계 자유 예측 손실을 추가한 방법이다. R·S1·SK는 공통 후보 계획기를 사용한다. 각 층의 독립 초기조건은 4개이며 신경망의 층별 12회는 4조건×학습 seed 3개다. 전체 독립 조건은 12개이며 36개가 아니다. 위치 5mm·방향 3°·선속도 0.01m/s·각속도 0.05rad/s 이하의 연속 0.3초 유지를 성공으로 판정하고 모든 실패를 분모에 남겼다.

방법	병진	회전	오프셋	인계 성공
G	4/4	1/4	3/4	8/12
R	0/4	0/4	0/4	0/12
S1	7/12	6/12	0/12	13/36
SK	6/12	6/12	0/12	12/36

S1 seed별 성공은 4/12·5/12·4/12, SK는 모두 4/12다. 회전 층에서 학습 계획기의 관측 비율은 G보다 높지만 독립 조건은 층당 4개다. 이를 해당 유형의 확정적 우위로 확대하지 않는다.

사후 짝분석에서 36쌍은 동시 성공12·동시 실패23·S1만 성공1·SK만 성공0이었다. 유일한 차이는 translation-03·seed23(S1 ready, SK timeout)으로, −2.78%p가 광범위한 악화를 뜻하지는 않는다. 36쌍은 독립 초기조건 36개가 아니다.

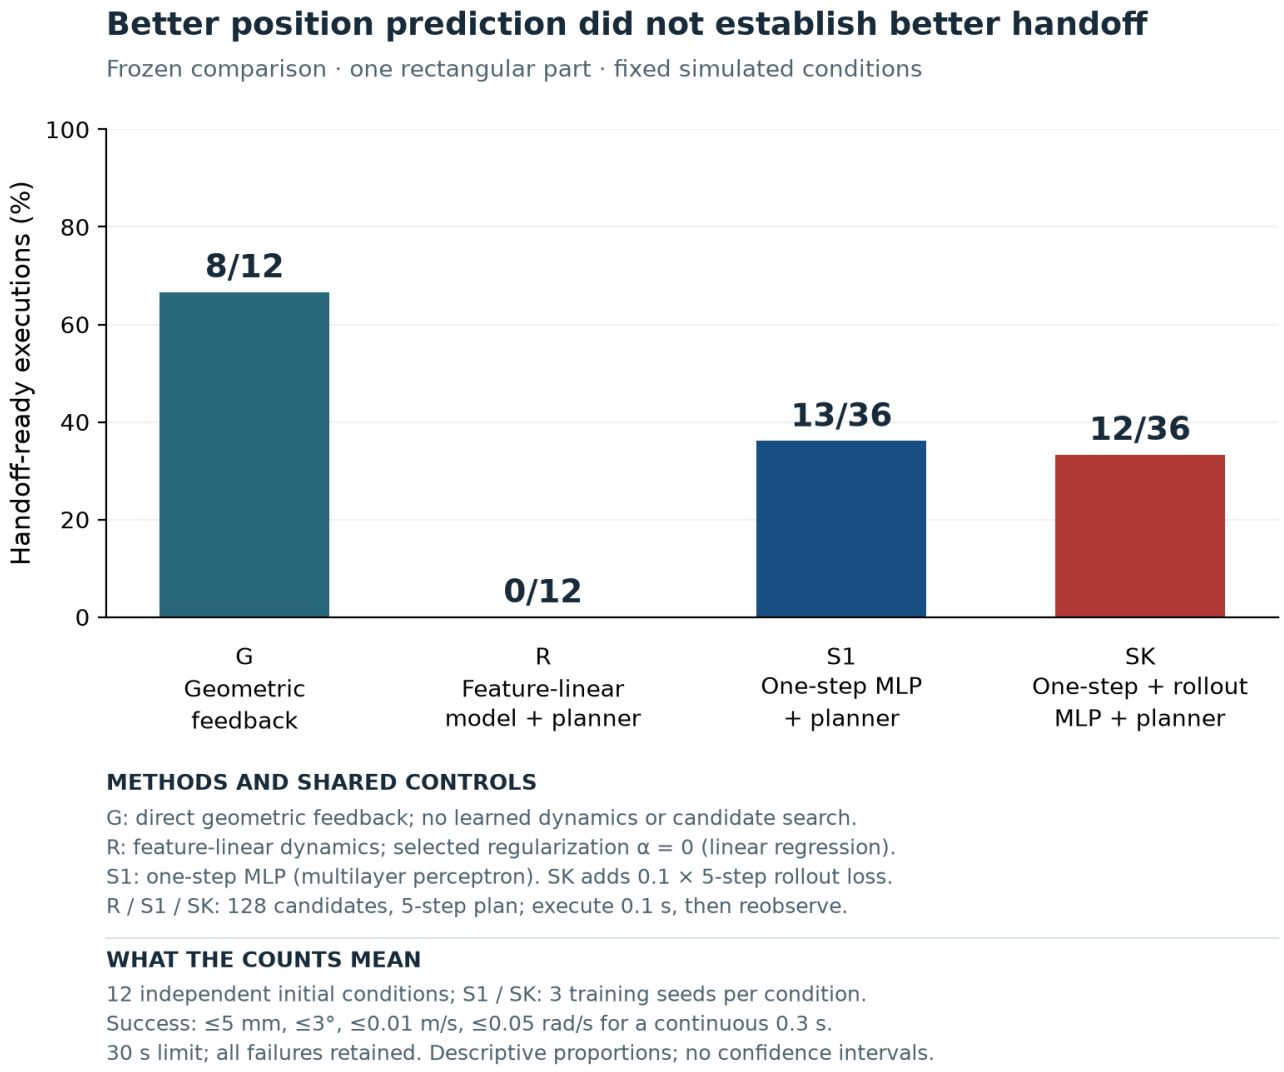


그림 1. 동결 조건의 인계 성공 비율과 실제 분모. G는 기하 피드백, R은 선형 예측, S1은 한 단계 학습 MLP, SK는 한 단계+0.1×5단계 자유 예측 학습 MLP다.

그림 1 설명. R의 선정 정규화는 α=0이다. R·S1·SK는 공통 128후보·5단계 계획기를 사용하며 G는 학습 예측·후보 탐색을 사용하지 않는다. 신경망의 36회는 독립 초기조건 12개×고정 학습 seed 3개이며 독립 조건 36개가 아니다. 막대는 실패를 포함한 관측 비율이고 신뢰구간을 그리지 않았다. 위치·방향·속도·연속 유지 기준은 그림 안에 표시했으며 실제 후속 집기·인계 동작을 수행했다는 뜻이 아니다.

표 2. 짝비교 인계 성공 비율 차이. G는 기하 피드백, R은 선형 예측(α=0), S1은 한 단계 학습 MLP, SK는 같은 MLP에 0.1 × 5단계 자유 예측 손실을 추가한 방법이다. 차이는 앞 방법−뒤 방법(%p)이다. 초기조건별 세 학습 seed(11·23·47)를 먼저 평균한 뒤 12개 독립 초기조건을 병진·회전·오프셋 층 안에서 2,000회 재표집한 95% percentile 구간이다. 이는 고정 학습 seed의 초기조건 재표집이며 학습 seed 모집단의 불확실성을 모두 포함하지 않는다. 다중비교 미보정의 탐색적 비교로 0을 포함해도 동등성을 입증하지 않는다.

짝비교	성공 차이 %p	95% bootstrap 구간
S1 - R	+36.11	[+16.67, +58.33]
SK - R	+33.33	[+8.33, +58.33]
S1 - G	-30.56	[-63.89, +2.78]
SK - G	-33.33	[-66.67, 0.00]
SK - S1	-2.78	[-8.33, 0.00]

고정 G 행동의 K5 물체 위치오차는 seed23에서 S1 0.090605mm→SK 0.058647mm, seed47에서 0.084235mm→0.068994mm였다. 각 family 평균을 12개 family에 동일 비중으로 평균한 값이다. 이 두 seed는 모든 공통 유효 창에서 예측이 유효했고 K10도 SK 오차가 작았다. 그러나 E2 성공은 각각 5/12→4/12, 4/12→4/12였다. seed11과 R은 예측 무효 마스크가 달라 유효 창 평균만으로 같은 모집단의 개선을 주장하지 않는다.

개선은 상태 성분 전체에 균일하지 않았다. seed47 K5의 yaw 오차는 0.013067→0.013516°, 각속도 오차는 0.000981→0.001030rad/s로 커졌다. K10은 K5 학습·H5 계획을 넘는 오프라인 진단이며 K10 폐루프 제어 성과가 아니다.

E1의 family 우선 평균 선택손실은 R 10.486563, S1 6.612161, SK 6.618703이었다. SK-S1 차이는 +0.006542, 구간 [0,+0.013085]로 개선을 지지하지 않았다. E1 모델 집합 84개에서 선택 없음·선택 후보 실제 무효는 0개였다. 이것이 E2의 모든 상태에서 유효 후보가 있다는 뜻은 아니다.

실제 제어 재현 33건은 채택됐고 저장 witness의 상태·명령·시각 최대 차이는 0이었다. 예약 family의 8 실행은 G만 28초에 ready였고 나머지 7개는 timeout이었다. 이는 동일 계약으로 작은 초기조건 변경을 실행할 수 있다는 증거이며, 신경망의 새로운 조건 성공이나 실물 일반화를 입증하지 않는다.

7. 관찰된 차이와 남은 원인 가설

서로 다른 평가에서 일부 위치 예측 개선, 드문 선택 차이, 인계 개선 미확인을 각각 관찰했다. 어느 연결이 병목인지는 확정하지 않았다. 평균 예측오차 → 후보별 비용·순위 → 선택 행동 → 실제 접촉 → 연속 인계 판정은 분석할 연결이며, 같은 개별 예측을 따라가 인과적으로 식별한 연결은 아니다.

7.1 확인된 사실

고정 행동 예측은 G가 방문한 상태와 행동에서 측정했다. E2는 각 모델이 스스로 선택한 행동으로 상태를 바꾼다. 평가 분포가 구조적으로 다르므로 고정 경로 예측 개선만으로 자체 정책의 미래 정확도를 보장할 수 없다. 분포 차이가 실제 실패를 얼마나 설명하는지는 아직 측정하지 않았다.

E1에서 S1/SK 동일 seed·snapshot 36쌍 중 35쌍은 같은 후보 번호를 골랐다. 유일한 차이는 translation-00, G tick29, seed47로 S1은 후보2·선택손실0, SK는 후보6·손실0.235521이었다. 이는 초기 접근 N16/H5 후보군의 드문 선택 차이이며 온라인 N128 전체 정책의 동일성은 아니다. E2의 유일한 성공 차이는 translation-03·seed23이므로 이 E1 사례로 설명할 수 없다.

실패 63개 중 종료 순간 위치 미충족은 62개, 방향은 38개, 각속도는 2개, 선속도는 0개였다. 조건별 수는 중복된다. 대부분을 단순한 정지 속도 문제라고 설명할 근거는 없다. G rotation-02는 마지막 네 순간 조건을 만족했지만 유지 시간이 0.0825초라 0.3초 기준을 충족하지 못했다. 정지 화면과 인계 완료는 다르다.

S1의 오프셋 3실행은 후보128개가 모두 predicted_deep_penetration으로 거절됐다. 이는 모델이 예측한 기하가 모두 유효성 검사를 통과하지 못했다는 관찰이다. 해당 후보들의 실제 미래는 이 실패 상태에서 실행하지 않았으므로 물리적으로 복구 불가능했다는 증거는 아니다.

7.2 남은 경쟁 가설과 구별 방법

가설	현재 지지·한계	구별할 다음 검사
오차 감소가 후보 순위를 바꿀 방향·크기가 아님	E1 35/36 같은 선택. 순위 여유와 오차의 관계는 미분석	저장 E1의 후보별 오차·비용 차이·실제 순위 여유 대응
자체 방문 상태에서 모델의 기하 예측이 나빠짐	G 평가와 정책 방문 분포가 다름. 최종 실패 상태 실제 라벨 부족	고정 실패 직전 상태·같은 후보에 두 모델과 실제 라벨 대조
비용이 연속 인계 목표를 충분히 대표하지 못함	개발 H10에서 실제 성공 후보보다 실패 후보의 비용이 낮았음	모델·예측·후보 고정 후 비용만 바꾸는 개발 비교
단일 접촉면·H5·후보 생성의 복구 범위가 제한됨	G 복구 불가 1건, S1 전후보 거절 3건. 단독 원인 미확정	예측/실제 기하 대조 후 후보 생성만 바꾸어 비교
학습 자료·손실이 접촉/정지를 충분히 반영하지 못함	P4 지원 범위 차이와 국소 오류 확인. 보완의 일관된 개선은 없음	분포·접촉상태를 맞춘 자료 대조와 실패 포함 평가

이 표는 후속 개발 질문이며 이번에 추가로 실행한 실험이 아니다. 저장 E1 분석은 접근 단계에서만 예측·비용·순위 관계를 확인할 수 있다. 종단 실패를 구별하려면 목표 공차 근처·실패 직전의 같은 전체 물리 상태에서 같은 후보의 예측·실제 미래 대조가 우선이다. 실제 실패상태 후보 실행과 비용·후보 변경은 별도 등록할 후속 개발 실험이며, 원래 동결 결과를 사후 교체하지 않는다.

8. 개발 과정에서 실제로 좁힌 설명

문제 정의 후 환경·입출력·접촉 물리를 먼저 검사하고, 자료 분할·정규화·기준선·공통 신경망을 준비했다. 이후 S1/SK 분기를 비교하고, 실제 실패에서 비용·접촉·정지 자료·학습항·갱신 방향의 가설을 순차적으로 좁혔다. 마지막에 원래 모델과 설정을 동결해 정식 비교했다. 아래 개발 결과는 최종 H5 정책의 인과 결론과 구분한다.

인계 비용을 검토한 한 개발 상태의 H10에서는 실제 인계한 후보11의 기존 비용9.586888이 인계하지 못한 후보60의8.804576보다 높았다. 비용과 작업 목적의 불일치가 존재하는 구체적 사례다. 인계 우선 비용으로 실제 후보11을 선호하도록 바꿔도, 모델이 후보77을 성공처럼 예측하는 오류는 남았다. 비용만 바꾸면 모델 오류까지 해결된다는 설명은 지지되지 않았다.

후보77의 실제 1초 실행에서는 옆면 접촉 진입이 없고 부품이 정지했다. 실제 상태를 다시 입력한 첫0.1초에서도 부품 오차0.365~0.414mm가 남아 재귀 누적만으로 설명할 수 없었다. 이는 개발 source99·seed11·선정 후보에 한정한다.

기존 train에는 영 명령164/3200행이 있었으나 연속 최장은0.2초, K5 영 명령 창은0개였다. 푸셔 Y속도·명령의 지원 범위 차이도 관찰했다. 따라서 정지 자료가 전혀 없었다고 말하지 않는다. 자료 유지군과 네 보완군의 재학습에서 일부 무효 예측은 줄었지만 Y/정지 주효과는 HOLD_INVALID_PRIMARY였고, 자료 보완이 실제 인계를 개선했다는 결론은 얻지 못했다.

같은 D11 자료·구조·예산에 상대위치 학습항만 추가한 R1은 정지 상대XY 오차0.614→1.193mm, 간격 절대오차0.596→0.839mm로 악화했다. 복사본의 Adam 방향·걸음 크기·교차 배치 진단은 일부 갱신 방향의 정지 손실 증가를 확인했지만, 누적 첫 모멘트를 제거해도 증가가 남았다. 실제 학습 전체나 최종 E2 실패를 단일 optimizer 원인으로 확정하지 않았다.

9. 한계와 해석

고정 형상·물성, 시뮬레이터 현재 상태 직접 관측, 제한된 초기 범위·접촉면, 작은 표본에 한정한다. 관측 노이즈·지연, 다품종·마찰 변화, 카메라, 일반 접촉면 전환, 실물 로봇과 후속 집기는 평가하지 않았다. 숨은 물리 상태에 대한 관측 표현의 충분성도 미확인이다.

R은 선형 모델의 기준선이며 분석적 밀기 모델·GP·불확실성 기반 계획 전체를 대표하지 않는다. 실제 동역학을 사용한 폐루프 계획 대조도 수행하지 않아 모델과 탐색·비용의 한계를 분리하지 못했다. 학습 목적의 충분한 수렴을 입증하지 않았으며, 후반 D11/R1 최적화 진단도 최종 분기의 수렴 근거가 아니다.

같은 초기조건의 세 학습 seed 실행을 추가적인 독립 초기조건으로 세지 않았다. 겹치는 예측 창·후보·물리 반복·검산 항목 수로 독립 표본 수를 늘리지 않았다. 예측 무효·계획 실패·timeout은 각각 원래 분모에 남겼다. 성공한 조건만의 평균 시간으로 전체 공정 시간 단축을 주장하지 않는다.

원래 결과·실패·중단을 보존했다. 복구는 같은 과학 조건의 실행 재시작이며 완전히 새로운 blind test는 아니다. 공개 저장소는 선별된 재현 묶음이다. 로컬 원시 전체·시스템 환경·모든 과거 진단까지 업로드했다는 뜻은 아니다. 공개본에서 확인할 수 있는 범위는 근거·재현 색인에 명시한다.

후속 목표 근처·실패 직전 진단 v1은 설계만 등록했다. 6상태·5초기조건에서 같은 128후보를 7모델과 실제 미래에 대조할 예정이다. 고정 명령 H5의 예측·비용 검사와 실제 정지 감독기·추가 영 명령 검사를 나누며, 거짓 무효·비용/준비 불일치·후보 커버리지를 별도 판정한다. 아직 snapshot 복원·모델 추론·새 미래 물리 실행은 수행하지 않았고, 기존 동결 결과의 인과적 한계가 해소된 것은 아니다.

10. 결론

학습 동역학을 구현하고 재귀 예측으로 행동을 선택하며 실제 인계 준비 조건까지 검사하는 목표는 달성했다. 일부 고정 행동의 위치 예측 개선은 확인했지만 SK의 후보 선택과 인계 개선은 확인하지 못했다. 이 결과는 학습 기반 계획 전체의 부정도, 방법 간 동등성의 증명도 아니다. 세 평가의 관찰과 실패를 보존했으며 종단 병목의 인과 규명은 남은 과제다.

사용자는 문제 가치와 학습 목표, 비교 기준, 진행·보류 판단을 논의하고 선택했다. Codex는 코드·학습·반복 실행·검산·시각화·문서 작성을 수행했다. 코드량이나 자동 검사 완료를 개인 역량의 대리 지표로 삼지 않는다. 다음 면접에서는 입력 계약·S1/SK 손실 차이·35/36 선택 일치의 해석·실패를 배제하지 않은 이유를 직접 설명할 수 있는지 별도로 확인할 수 있다.

부록 A. PDF만으로 확인하는 핵심 증거

항목	관측값	해석 경계
실행·원래 분모	E2 96; G/R 각12, S1/SK 각36	독립 family12, 합계 성공33/96을 단일 정책 성능으로 쓰지 않음
종료	ready33, timeout59, 제어 불가1, 계획 무효3	저장 오류·미실행과 구분
실패 최종 조건	위치62, 방향38, 각속도2, 선속도0	실패63개 중 중복 집계, 인과 원인 아님
선택 진단	E1 576실행, 84모델 집합	독립 family6, 유한N16 후보의 진단
S1/SK 선택 일치	35/36쌍	G 상태·N16/H5에 한정
작은 적용	예약1family 8방법, G만ready	본96과 분리, 새 태스크·실물 일반화 아님
실제 제어 재현	33사례 채택	표 재생성과 실제 실행 재현을 구분

부록 B. 재현 단계와 문서 운영

Markdown은 수정·차이 검토·GitHub 탐색용 원본이고 PDF는 같은 원고에서 만든 읽기·제출용 결과다. 핵심 목표표·수치·실패·가설은 PDF 본문과 부록에 직접 수록했다. 별도 MD를 열지 않아도 결론과 한계를 이해할 수 있다. 세부 수치·코드·가중치는 저장소의 상대 링크로 연결하며, 내려받은 PDF의 링크는 공개 저장소 주소로 연결한다.

공개 자료의 SHA와 수치 확인 → 실제 모델 로드·1/5단계 예측 → 필요시 작은 물리 실행 순으로 검토한다. 전체 원시를 전제로 하는 기존 최종 실행·독립 감사 명령은 공개본만으로 완전 재생된다고 보장하지 않는다. 정확한 실행 명령·설치 환경·포함 및 생략 파일은 근거·재현 색인에 있다. 원래 28단계 완료 판정과 이번 공개본의 설치·문서 검증을 구분한다.

참고문헌

[1] Fortville Feeders. Dual three-position shuttle for small, lightweight parts. 2022. 기업 원문. 작업·설비가 다른 단일 사례이며 학습 도입 근거가 아니다.

[2] Yu, K.-T., Bauza, M., Fazeli, N., Rodriguez, A. More than a Million Ways to Be Pushed: A High-Fidelity Experimental Dataset of Planar Pushing. IROS, 2016. 원문. 본 프로젝트는 해당 실물 자료를 학습한 직접 재현이 아니다.

[3] Bauza, M., Hogan, F. R., Rodriguez, A. A Data-Efficient Approach to Precise and Controlled Pushing. CoRL, PMLR 87, 336-345, 2018. 출판사 원문. GP+MPC 선행 접근이며 본 MLP 결과의 성능을 대신 입증하지 않는다.

[4] Lambert, N., Amos, B., Yadan, O., Calandra, R. Objective Mismatch in Model-Based Reinforcement Learning. L4DC, PMLR 120, 761-770, 2020. 출판사 원문. 예측 학습과 제어 목적의 차이를 다룬 선행 연구다.

[5] Venkatraman, A., Hebert, M., Bagnell, J. A. Improving Multi-Step Prediction of Learned Time Series Models. AAAI 29(1), 2015. 출판사 원문. DaD 방식이며 이번 자유 예측 손실의 직접 재현이나 이론 보장 근거로 사용하지 않는다.